Homework 10

Ameth FAYE

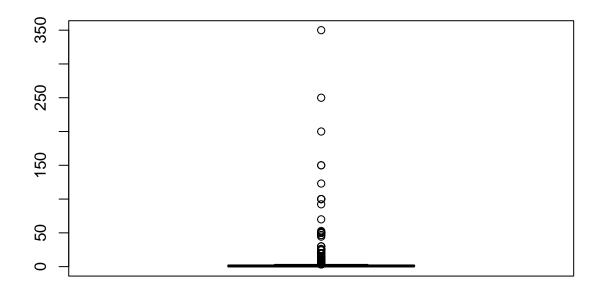
2024-03-30

```
#Exercice de maison 10:
source("C:/Users/HP/Desktop/ISEP2CoursR2024/Homework 7.R")
## New names:
## * '' -> '...8'
## * ' ' -> ' ... 9 '
## Warning: le package 'dplyr' a été compilé avec la version R 4.3.3
## -- Attaching core tidyverse packages ------ tidyverse 2.0.0 --
## v dplyr 1.1.4
                     v readr
                                2.1.4
## v forcats 1.0.0
                      v stringr 1.5.0
## v ggplot2 3.4.3
                   v tibble
                                 3.2.1
                      v tidyr
## v lubridate 1.9.2
                                 1.3.0
## v purrr
             1.0.2
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag() masks stats::lag()
## i Use the conflicted package (<a href="http://conflicted.r-lib.org/">http://conflicted.r-lib.org/</a>) to force all conflicts to become error
## Rows: 11,114
## Columns: 14
## $ interview__key
                       <chr> "55-75-97-43", "55-75-97-43", "55-75-97-43", "1~
                         <chr> "3827f11c978e42e6aa4b5b8ed9aa1348", "3827f11c97~
## $ interview__id
## $ cereales__id
                         <dbl+lbl> 1, 7, 20, 4, 22, 1, 7, 16, 21, 1, 20,~
## $ s07Bq03a_cereales
                     <dbl> 9.00, 7.00, 2.00, 7.50, 42.00, 14.00, 10.00, 0.~
## $ s07Bq03b_cereales
                         <dbl+lbl> 100, 100, 139, 100, 568, 100, 100, 100, 568~
                         <dbl+1bl> 0, 0, 2, 0, 3, 0, 0, 0, 3, 0, 2, 3, 0, 2, 0~
## $ s07Bq03c_cereales
## $ s07Bq04_cereales
                         <dbl> 0, 7, NA, NA, 0, 0, 10, 0, 0, 0, NA, 0, 0, 7, 0~
## $ s07Bq05_cereales
                         <dbl+lbl> 2, 4, 2, 1, 1, 2, 4, 1, 1, 1, 2, 1, 4, 4, 2~
## $ s07Bq06_cereales
## $ s07Bq07a_cereales
                         <dbl> 1.00, NA, 2.00, 2.50, 6.00, 2.00, NA, 0.25, 1.0~
## $ s07Bq07b_cereales
                         <dbl+lbl> 100, NA, 139, 100, 568, 100, NA, 100, 568~
                         <dbl+lbl> 0, NA, 2, 0, 3, 0, NA, 0, 3, 0, 2,~
## $ s07Bq07c_cereales
                         <dbl> 350, NA, 600, 750, 1050, 325, NA, 200, 200, 120~
## $ s07Bq08_cereales
## Rows: 11,104
## Columns: 15
## $ interview__key <chr> "55-75-97-43", "55-75-97-43", "55-75-97-43", "14-16-03-~
## $ interview__id <chr> "3827f11c978e42e6aa4b5b8ed9aa1348", "3827f11c978e42e6aa~
```

```
## $ Qtty_cons
                 <dbl> 9.00, 7.00, 2.00, 7.50, 42.00, 14.00, 10.00, 0.25, 7.00~
                  <dbl+lbl> 100, 100, 139, 100, 568, 100, 100, 100, 568, 100, 1~
## $ Unite_cons
## $ Taille_cons
                  <dbl+lbl> 0, 0, 2, 0, 3, 0, 0, 0, 3, 0, 2, 3, 0, 2, 0, 3, 0, ~
## $ AutoCons
                 <dbl> 0, 7, NA, NA, 0, 0, 10, 0, 0, NA, 0, 0, 7, 0, 0, ~
                 ## $ AutresProv
                 <dbl+lbl> 2, 4, 2, 1, 1, 2, 4, 1, 1, 1, 2, 1, 4, 4, 2, 1, 1, ~
## $ DernierAchat
## $ Qtty_achat
                 <dbl> 1.00, NA, 2.00, 2.50, 6.00, 2.00, NA, 0.25, 1.00, 3.00,~
## $ Unite_achat
                 <dbl+lbl> 100, NA, 139, 100, 568, 100, NA, 100, 568, 100, 1~
## $ Taille_achat
                 <dbl+lbl> 0, NA, 2, 0, 3, 0, NA, 0, 3, 0, 2, 3, NA,~
                  <dbl> 350, NA, 600, 750, 1050, 325, NA, 200, 200, 1200, 800, ~
## $ Value_achat
## $ produit1
                  <fct> 1, 7, 20, 4, 22, 1, 7, 16, 21, 1, 20, 21, 1, 6, 7, 21, ~
## Rows: 11,104
## Columns: 16
## $ interview_key <chr> "55-75-97-43", "55-75-97-43", "55-75-97-43", "14-16-03-~
## $ interview__id <chr> "3827f11c978e42e6aa4b5b8ed9aa1348", "3827f11c978e42e6aa~
## $ cereales id
                  <dbl+lbl> 1, 7, 20, 4, 22, 1, 7, 16, 21, 1, 20, 21, 1,~
## $ Qtty_cons
                 <dbl> 9.00, 7.00, 2.00, 7.50, 42.00, 14.00, 10.00, 0.25, 7.00~
## $ Unite_cons
                 <dbl+lbl> 100, 100, 139, 100, 568, 100, 100, 100, 568, 100, 1~
## $ Taille cons
                 <dbl+lbl> 0, 0, 2, 0, 3, 0, 0, 0, 3, 0, 2, 3, 0, 2, 0, 3, 0, ~
                 <dbl> 0, 7, NA, NA, 0, 0, 10, 0, 0, NA, 0, 0, 7, 0, 0, ~
## $ AutoCons
## $ AutresProv
                 ## $ DernierAchat
                 <dbl+lbl> 2, 4, 2, 1, 1, 2, 4, 1, 1, 1, 2, 1, 4, 4, 2, 1, 1, ~
## $ Qtty_achat
                 <dbl> 1.00, NA, 2.00, 2.50, 6.00, 2.00, NA, 0.25, 1.00, 3.00,~
## $ Unite_achat
                  <dbl+lbl> 100, NA, 139, 100, 568, 100, NA, 100, 568, 100, 1~
## $ Taille_achat
                 <dbl+lbl> 0, NA, 2, 0, 3, 0, NA, 0, 3, 0, 2, 3, NA,~
## $ Value_achat
                 <dbl> 350, NA, 600, 750, 1050, 325, NA, 200, 200, 1200, 800, ~
## $ produit1
                 <fct> 1, 7, 20, 4, 22, 1, 7, 16, 21, 1, 20, 21, 1, 6, 7, 21, ~
## $ produit
                 <fct> "Riz local brisé", "Mil", "Pâtes alimentaires", "Riz im~
Table_de_conversion <- read_excel("C:/Users/HP/Desktop/ISEP2CoursR2024/Base/Table de conversion phase 2
## New names:
## * '' -> '...8'
## * '' -> '...9'
colnames(Table_de_conversion) [1:6] <- c("cereales__id","Nom_Prod",</pre>
                                    "Unite_cons", "Nom_Unite",
                                    "Taille_cons", "Nom_Taille")
cereales <- merge(cereales, Table_de_conversion,</pre>
                by = c("cereales_id", "Unite_cons", "Taille_cons"), all.x = TRUE)
# Traitement de la base de données
library(data.table)
## Attachement du package : 'data.table'
## Les objets suivants sont masqués depuis 'package:lubridate':
```

```
##
##
      hour, isoweek, mday, minute, month, quarter, second, wday, week,
##
      yday, year
##
## Les objets suivants sont masqués depuis 'package:dplyr':
##
##
      between, first, last
##
## L'objet suivant est masqué depuis 'package:purrr':
##
##
      transpose
cereales4 <- data.table(cereales)</pre>
setnames(cereales4 ,"poids","poids_cons")
cereales4 [,poids_cons:=as.numeric(poids_cons)] # Conversion de la variable poids_cons
cereales4 [,qtty_cons_kg:= poids_cons*Qtty_cons/1000] ## Quantité consommée en kg
#' calculer la quantite achete en kg;
cereales4 <- cereales4 [, Unite_achat := as.double(Unite_achat)]</pre>
cereales4 <- cereales4 [, Taille_achat := as.double(Taille_achat)]</pre>
cereales4 <- cereales4 [, cereales__id := as.double(cereales__id)]</pre>
colnames(Table_de_conversion) [1:6] <- c("cereales__id","Nom_Prod",</pre>
                                   "Unite_achat", "Nom_Unite",
                                   "Taille_achat", "Nom_Taille")
glimpse(Table_de_conversion)
## Rows: 1,367
## Columns: 9
## $ cereales__id <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, ~
               <chr> "Riz local brisé", "Riz local brisé", "Riz local brisé", ~
## $ Nom Prod
## $ Unite_achat <dbl> 100, 108, 108, 108, 108, 136, 138, 139, 100, 108, 108, 10~
## $ Nom Unite
               <chr> "Kg", "Boite de tomate/Pot", "Boite de tomate/Pot", "Boit~
## $ Taille_achat <dbl> 0, 1, 2, 3, 7, 0, 0, 2, 0, 1, 2, 3, 7, 0, 0, 2, 0, 1, 2, ~
              <chr> "taille unique", "Petit", "Moyen", "Grand", "Tres petit",~
## $ Nom Taille
               <chr> "1000", "521.5", "935", "1997.5", "222", "25000", "50000"~
## $ poids
## $ ...8
               ## $ ...9
               cereales4 <- merge(cereales4 , Table_de_conversion,</pre>
                by = c("cereales_id", "Unite_achat", "Taille_achat"), all.x = TRUE)
cereales4 <- data.table(cereales4 )</pre>
glimpse(cereales4)
## Rows: 11,104
## Columns: 33
## $ cereales__id
                   ## $ Unite_achat
                   ## $ Taille_achat
                   ## $ Unite cons
```

```
## $ Taille cons
             <chr> "44-02-17-24", "66-45-81-17", "86-55-10-95", "63-35-~
## $ interview__key
## $ interview id
             <chr> "b469453f8410449290ba3cd8ca1c4833", "3e6feed83915499~
## $ AutresCereales
             <dbl> 14.00, 1.50, 10.50, 12.00, 10.50, 25.00, 7.00, 7.00,~
## $ Qtty cons
## $ AutoCons
             <dbl> 0.00, 1.50, 0.00, 0.00, 0.00, 25.00, 0.00, 0.00, 10.~
## $ AutresProv
             <dbl> 0.0, 0.0, 10.5, 0.0, 0.0, 0.0, 0.0, 7.0, 0.0, 0.0, 0~
             ## $ DernierAchat
## $ Qtty achat
             ## $ Value_achat
             ## $ produit1
             <fct> "Riz local brisé", "Riz local brisé", "Riz local bri~
## $ produit
             ## $ unite_cons
## $ taille_cons
             <fct> Taille unique, Taille unique, Taille unique, Taille ~
## $ classCereal
             <fct> Tres faible, Tres faible, Tres faible, ~
## $ Nom_Prod.x
             <chr> "Riz local brisé", "Riz local brisé", "Riz local bri~
             <chr> "Kg", "Kg", "Kg", "Kg", "Kg", "Kg", "Kg", "Kg", "Kg", "Kg"~
## $ Nom Unite.x
             <chr> "taille unique", "taille unique", "taille unique", "~
## $ Nom_Taille.x
             <dbl> 1000, 1000, 1000, 1000, 1000, 1000, 1000, 1000, 1000~
## $ poids cons
## $ ...8.x
             ## $ ...9.x
             <dbl> 14.00, 1.50, 10.50, 12.00, 10.50, 25.00, 7.00, 7.00,~
## $ qtty_cons_kg
## $ Nom Prod.y
             ## $ Nom Unite.y
## $ Nom Taille.y
             ## $ poids
             ## $ ...8.y
             ## $ ...9.y
setnames(cereales4 , "poids_cons", "poids_achat")
cereales4 <- cereales4 [,poids_achat:=as.numeric(poids_achat)]</pre>
cereales4 [, qtty_achat_kg := Qtty_achat*poids_achat/1000]
boxplot(cereales4 $qtty_achat_kg)
```



```
#' calculer le prix unitaire ;
## Un prix unitaire pour chaque combinaison (produit, unite, taille)
cereales4 $pu <- cereales4 $Value_achat/cereales4 $Qtty_achat</pre>
### Extraire les Prix
prixunitaire <- subset(cereales4 , !is.na(pu),</pre>
                        select =c("cereales_id", "Unite_achat", "Taille_achat", "pu") )
## Traitement des pu aberrants ;
idc <- unique(cereales4 $cereales__id)</pre>
library(dplyr)
cereales4 <- cereales4 %>%
  group_by(cereales__id) %>%
  mutate(pu = ifelse(!is.na(pu) & pu > quantile(pu, 0.75, na.rm = TRUE), quantile(pu, 0.75, na.rm = TRU
\# Calculer la moyenne et la médiane de 'pu' pour chaque combinaison (p,u,t)
library(dplyr)
resultats <- prixunitaire %>%
  group_by(pu, Unite_achat, Taille_achat) %>%
 summarise(
```

```
mediane_pu = median(pu, na.rm = TRUE)
## 'summarise()' has grouped output by 'pu', 'Unite_achat'. You can override using
## the '.groups' argument.
# Calculer le prix 'p' pour chaque combinaison (p,u,t)
prixunitaire2 <- prixunitaire %>%
  group_by(pu, Unite_achat, Taille_achat) %>%
  summarise(
   p = mean(pu, na.rm = TRUE)
## 'summarise()' has grouped output by 'pu', 'Unite achat'. You can override using
## the '.groups' argument.
#' Ramener cette sous-base dans la base cereales4 pour calculer
#' les depenses de consommations ;
library(dplyr)
# Joindre la sous-base 'prixunitaire' à la base 'cereales4'
cereales4 <- cereales4 %>%
 left_join(prixunitaire2, by = c("pu", "Unite_achat", "Taille_achat"))
# Calculer les dépenses de consommation
cereales4 <- cereales4 %>%
 mutate(depenses = p * Qtty_achat)
#' 1:: evaluer le taux de matching : n(Pc, Uc, Tc) aynt un prix P sur le
#' le nombre total de combinaison n(Pc,Uc,Tc);
# Calculer le nombre total de combinaisons (Pc, Uc, Tc)
total_combinaisons <- nrow(cereales4 )</pre>
# Calculer le nombre de combinaisons (Pc, Uc, Tc) ayant un prix P
combinaisons_avec_prix <- cereales4 %>%
 filter(!is.na(p)) %>%
 nrow()
# Calculer le taux de correspondance
taux_correspondance <- combinaisons_avec_prix / total_combinaisons</pre>
# Afficher le taux de correspondance
print(taux_correspondance)
## [1] 0.8444705
#' 2:: Reflechir a comment valoriser ces quantites n'ayant de prix
```

```
# Imputer les valeurs manquantes par la médiane
cereales4 $pu[is.na(cereales4 $pu)] <- median(cereales4 $pu, na.rm = TRUE)

#' Valeurs aberrantes :: corrections ;
Q1 <- quantile(cereales4 $pu, 0.25, na.rm = TRUE)
Q3 <- quantile(cereales4 $pu, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1

# Remplacer les valeurs aberrantes par la médiane
cereales4 $pu[cereales4 $pu < (Q1 - 1.5 * IQR) | cereales4 $pu > (Q3 + 1.5 * IQR)] <- median(cereales4 *pu)</pre>
```